

2025年度 卒業論文

擬音語認識モデルの学習のための
連結環境音の構成法

2026年2月13日

システム工学科
学生番号: 60276266

森山 颯太

和歌山大学システム工学部

概要

本研究では, End-to-End 型擬音語認識モデルの学習データに関する検討を行った. 認識モデルの学習には, 環境音ペアデータ (環境音のセグメント+紐づいたオノマトペ (テキスト)) を用いて作成した無作為型と反復型の 2 種類の連結環境音信号を利用した. 無作為型とは, 環境音ペアデータをランダムに 10 個連結した音響信号であり, 反復型は, 環境音ペアデータ 2 個を 5 回繰り返し連結した音響信号を指す. 先行研究において, 反復型を学習データとして用いた際に繰り返しパターンを含む環境音のリズム感を再現できた一方, 繰り返しを含まない環境音に対して「不自然な繰り返し」が生じる課題が確認された. この誤った出力の抑圧に向けて, 擬音語の多様性の制限 (仮説 1), 反復型の除外 (仮説 2), 無作為型の増量 (仮説 3) という 3 つの仮説を立て, 4 条件の学習データで認識モデルを構築した. 実験では, 主観評価により妥当率の比較を行った. 比較の結果, 擬音語の多様性の制限をし, 無作為型のみを用いたモデル (条件 1) は, 擬音語の多様性の制限をし, 反復型を混合したモデル (条件 3) よりも, 瞬発性のある環境音や不規則なリズムの反復音の入力に対して高い妥当率を示した. 具体的には, 瞬発性のある環境音である「缶を開ける音」で 38.7% (条件 3 は 25.3%), 「ガラスが割れる音」で 30.7% (条件 3 は 22.7%) の妥当率となった. また, 不規則な反復音である「ドアのノック音」では 46.7% (条件 3 は 28.0%), 「マウスのクリック音」では 28.0% (条件 3 は 16.0%) となり, 擬音語の多様性を制限することと反復型を認識モデルの学習から除外することで不自然な繰り返しの抑制 (瞬発性のある環境音の妥当率の向上) や一部の反復性のある環境音の入力に対する認識性能の維持に有効であることを確認した. 一方で, 無作為型を増量した条件 2 の妥当率の全体平均は 32.0% に留まり, 条件 1 の 36.7% を下回る結果となった.

キーワード: 擬音語認識システム, 環境音, オノマトペ, Hybrid-CTC/Attention

目次

第1章	はじめに	1
1.1	研究背景	1
1.2	関連研究	1
1.3	研究目的	3
1.4	本論文の構成	3
第2章	擬音語認識システムの実装	4
2.1	CTC(Connectionist Temporal Classification)	4
2.2	Transformer モデル	5
2.2.1	Attention 機構	5
2.2.2	Feed-Forward 層	6
2.3	Conformer モデル	7
2.3.1	Multi-Head Self Attention モジュール	8
2.3.2	Convolution モジュール	8
2.3.3	Feed-Forward モジュール	9
2.3.4	Conformer ブロック	10
2.4	Hybrid-CTC/Attention モデル	10
2.5	ESPnet2	12
2.5.1	モデルの訓練条件	12
2.6	本章のまとめ	12
第3章	仮説とモデルの学習に使用する連結環境音信号の準備	14
3.1	RWCP-SSD-Onomatopoeia	14
3.1.1	自信度と許容度	14
3.1.2	データセットの整形	15
3.2	連結環境音信号の作成方法	15
3.3	評価用環境音サンプル ESC-50	16
3.3.1	クラスの分類	16
3.4	本研究の仮説	17
3.5	予備実験（モデルの学習に使用するデータ数の検討）	17
3.6	本実験で利用した学習データ作成条件	19
3.7	本章のまとめ	19
第4章	主観評価による仮説の検証	21
4.1	主観評価実験の方法	21
4.2	主観評価実験の結果と考察	21
4.2.1	仮説1（条件3と条件4）の比較結果	23
4.2.2	仮説2（条件1と条件3）の比較結果	23
4.2.3	仮説3（条件1と条件2）の比較結果	24

4.2.4	質問 1 と質問 2 の「○」回答数の比較	24
4.2.5	実際の出力例	24
4.3	本章のまとめ	25
第 5 章	おわりに	30
5.1	まとめ	30
5.2	今後の課題	30

目 次

2.1	Transformer の構成	6
2.2	Transformer ブロック	7
2.3	(左)Self-Attention (右)Source-Target Attention	7
2.4	Multi-Head Attention の構造	8
2.5	Conformer の Encoder 構造と Conformer ブロックの構造	9
2.6	Multi-Head Self Attention モジュールの構造	9
2.7	Convolution モジュールの構造	10
2.8	Swish 関数のグラフ	10
2.9	Conformer ブロックの FFN モジュール	11
2.10	Hybrid-CTC/Attention の構造 (Share Encoder : Conformer)	11
3.1	無作為型の連結例	16
3.2	反復型の連結例	16
3.3	予備実験結果 (「○」のみ, 横軸: 学習データの数, 縦軸: 妥当率 [%])	18
3.4	予備実験結果 (「○」と「△」, 横軸: 学習データの数, 縦軸: 妥当率 [%])	18
4.1	評価実験で利用した Google フォーム	26
4.2	実験結果: 仮説 1 (多様性の制限) に関する比較 (左: 質問 1 「忠実な書き起こし」, 右: 質問 2 「擬音語として妥当」)	27
4.3	実験結果: 仮説 2 (無作為型のみ) に関する比較 (左: 質問 1 「忠実な書き起こし」, 右: 質問 2 「擬音語として妥当」)	27
4.4	実験結果: 仮説 3 (データ量の増大) に関する比較 (左: 質問 1 「忠実な書き起こし」, 右: 質問 2 「擬音語として妥当」)	27

表 目 次

2.1	Hybrid CTC/Attention モデルの学習条件	13
3.1	上：環境音のセグメントの数 下：付与されたオノマトペの総数	15
3.2	実験で比較したモデルの学習条件（4 条件）	19
4.1	質問 1：クラス別の妥当率 [%] の平均（「○（妥当）」と回答した数/回答者数） . .	22
4.2	質問 2：クラス別の妥当率 [%] の平均（「○（妥当）」と回答した数/回答者数） . .	22
4.3	質問 1「忠実な書き起こし」と質問 2「擬音語として妥当」の回答「○」の数の差 （質問 2-質問 1）	28
4.4	事例「時計のアラーム音」に対する「○」の回答数	29
4.5	事例「タイピング音」に対する「○」の回答数	29

第1章 はじめに

1.1 研究背景

近年, AI (Artificial Intelligence) による音声対話技術が飛躍的に発展している. しかし, 対話システムの中で利用される一般的な音声認識技術は「人の声」以外の音, すなわち環境音を受理することが困難である. 本来, 円滑なコミュニケーションは言語情報のみの交換ではなく, 非言語情報を考慮したその場の状況理解に基づいて成立する. したがって, 環境音を認識できないことは, 人間とシステム間の親和性を高める上での大きな障壁となっている.

例えば, 突発的なガラスの破損音に対し, システムが「ガシャンと音がしましたが, 大丈夫ですか?」と即座に状況に沿った声掛けができれば, より人間に近い共感的な対話が可能となる.

また, 環境音を擬音語 (オノマトペ) として認識・可視化する技術には, エンターテインメント分野においても需要が存在する. 具体的には, 映画やアニメーションにおける聴覚障害者向けの「音の字幕 (オノマトペ字幕)」の自動生成や, 漫画制作においては臨場感を高めるための擬音語の選定・配置支援などが挙げられる. 環境音を言語化 (擬音語化) する技術は, 情報のアクセシビリティ向上とクリエイティブな表現の拡張という, 両側面において重要な役割を担うものである.

本研究では, このような音響信号を入力とする擬音語認識手法の技術的な確立に向けて, 現在の深層学習の主流である End-to-End 型モデルの適用による課題解決を目指す.

1.2 関連研究

関連研究として, 岡本ら [1] は, オノマトペの入力から環境音を合成する Onoma-to-Wave を提案している. その中では, 与えられたオノマトペを構成するサブワードと紐づいた環境音のサンプルを組み合わせて信号を生成する従来の手法とは異なり, 深層学習モデルを用いてオノマトペに対応する信号波形を直接的に合成している.

この論文では, 深層学習モデルの構築において2つの条件を比較している. 1つ目は, 深層学習モデルの学習に環境音の音響信号とそのアノテーションであるオノマトペのテキストを用いた条件であり, 2つ目には, 学習データに環境音の音響信号とそのアノテーションであるオノマトペ, 音響イベントラベルの3つのデータセットとして用いている. この2つ目の条件は, 1つのオノマトペが異なる複数の環境音を表す場合に対応することがあるために検討に加えられている.

実装は, Seq2seq (Sequence-to-Sequence) [2] フレームワークを採用して実現しており, Model training block と Sound synthesis block の2つのブロックで構成される. Model training block では, オノマトペと環境音のペアデータを用いてモデルの学習を行なっている. その深層学習モデルは, Encoder-Decoder 構造を持ち, Encoder は1層の BiLSTM (Bidirectional Long Short-Term Memory) [3], Decoder は2層の LSTM (Long Short-Term Memory) [4] で構成している. このと

き, 深層学習モデルの内部パラメータ λ を, オノマトペの音素系列を l , 環境音の音響特徴量である対数振幅スペクトログラムを o としたとき, 式 1.1 に基づいて算出している.

$$\hat{\lambda} = \operatorname{argmax}_{\lambda} P(o|l, \lambda) \quad (1.1)$$

Sound synthesis block では, 学習したモデルを用いてオノマトペから環境音を合成する. 入力のおノマトペの音素系列 l として, 合成される環境音の音響特徴量を o としたとき, 式 1.2 になる.

$$\hat{o} = \operatorname{argmax}_o P(o|l, \hat{\lambda}) \quad (1.2)$$

推定された音響特徴量 $\hat{o}$ から環境音の波形合成には, Griffin-Lim アルゴリズム (GLA) [5] を使用している. GLA は, 位相情報が失われたスペクトログラムから, 元の波形を推定する反復アルゴリズムである.

ここまでの Onoma-to-Wave では, RWCP-SSD[6] に含まれる環境音のサンプルとそれに対応する RWCP-SSD-Onomatopoeia[7] のオノマトペの書き起こしを深層学習モデルを学習する際のペアデータとしている. 評価においては, 主観評価実験が行われており, 合成された環境音の自然さと, 多様性を評価基準としている.

結果として, 従来手法よりも自然さと多様性の両方で優位性を示した. また, 音響イベントラベルを併用して学習した深層学習モデルによって, 合成された環境音の継続長のみではなく, 音響イベントの種類についても制御できることを示した.

合成系の研究がある一方で, 環境音を入力とし, 擬音語を出力する擬音語認識では, 従来, MFCC (メル周波数ケプストラム係数) と HMM (隠れマルコフモデル) を用いた階層型アルゴリズムによって, 音節単位の認識を行う検討が進められてきた [9].

我々の研究室においては, 松浪 [10] は, 無作為型データと反復型データの 2 種類の連結環境音データを用いた End-to-end 型擬音語認識モデルを提案した. 深層学習モデルの学習に用いるデータセットを準備する際には, 岡本ら [1] のモデル学習にも用いた擬音語ラベルが付与された RWCP-SSD-Onomatopoeia を利用している. また, 評価データとして ESC-50[8] を使用した.

無作為型データ (以下, 無作為型) とは, 環境音のセグメントをランダムに 10 個連結した音響信号である. 反復型データ (以下, 反復型) は, 環境音のセグメント 2 個を 5 回繰り返して連結した音響信号から構成されている. この際, 各環境音セグメントに対応する擬音語ラベルも連結している. これら 2 種類の連結環境音データを混合してモデルを学習することで, 繰り返しを含む環境音の入力に対して認識結果にリズム感を再現することに成功している.

さらに, 学習データに含む反復型の割合を 10%, 20%, 30%, 40%, 50% で変えた場合の認識結果について主観評価で比較した. その結果, 学習データに含む反復型の割合が 20% のとき, 最も適合率が高い結果を示した. この時の擬音語認識の出力の具体例は以下のようになっている.

- 無作為型のみで学習したモデルの場合

チャッガッバッガッガッガッガッガッガッカッカン (時計の針の音)
パッシャッ (缶を開ける音)

- 反復型と無作為型を混合したデータで学習したモデルの場合

ガッコンガッコンガッコンガッコンガッコン (時計の針の音)

チリンカッチリン（缶を開ける音）

松浪 [10] では、深層学習モデルの学習データに含まれる反復型の割合を 20%が適当としたが、反復型を学習データに含めたため、繰り返しを含まない環境音の入力に対しても、不自然で本来は存在しない繰り返しパターンが出力に含まれる事例が確認されている。

1.3 研究目的

本研究の目的は、松浪 [10] の提案手法（以降、先行研究 [10]）において課題となった、繰り返しパターンを含まない環境音の入力に対して「不自然な繰り返し」の出力を抑制しつつ、繰り返しパターンを含む環境音の入力における「リズム感」の再現を両立することである。つまり、繰り返しパターンを含まない環境音の入力に対して認識性能を向上させ、繰り返しパターンを含む環境音の認識性能に関しては先行研究 [10] を維持することを目標とする。

先行研究 [10] では無作為型と反復型を混合して深層学習モデルの学習に用いることで、「時計の針の音」などの周期的な音に対してリズム感のある擬音語出力を可能とした。しかし、この手法は繰り返しパターンを含まない環境音の入力に対しても、学習データの特徴に引きずられる形で反復的な擬音語の認識結果を生じさせてしまう副作用のような影響がある。1.1 節で述べた音の字幕化や対話支援への応用を想定した場合、繰り返しを含まない環境音に対して過剰な繰り返し表現が出力されることは、利用者に状況の誤認を招く恐れがあり、システムの信頼性を担保する上での大きな障害となる恐れがある。

この問題を検討するため、本研究では深層学習モデルの学習に用いる連結環境音信号の構成に着目し、以下の 3 つの仮説に基づいた比較検討を行う。

- 仮説 1：あえて種類を減らした擬音語をランダムに連結して繰り返しパターンを表現できる
- 仮説 2：反復型をモデルの学習に含めないことで不自然な繰り返しの出力を抑制できる
- 仮説 3：無作為型のみで学習データを作成するとして、使用するデータの量を増やすことで繰り返しパターンを表現できる

この検討を通じて、入力環境音に含まれる繰り返しパターンの有無等に関わらず、常に人間にとって妥当性の高い擬音語を出力可能とする、End-to-End 型擬音語認識技術を確立することを目的とする。

1.4 本論文の構成

本論文は 5 章で構成されている。第 1 章では、研究背景、先行研究 [10] および研究目的について述べた。第 2 章では、本研究を理解するうえで必要な前提知識と要素技術を解説する。第 3 章では、深層学習モデルの学習に利用する連結環境音の作成手順を説明する。また、予備実験と本実験のために準備した学習データの作成条件を示す。第 4 章では、構築した擬音語認識モデルの評価実験の方法と結果を示す。第 5 章では、本研究をまとめ、今後の課題を示す。

第2章 擬音語認識システムの実装

本章では、擬音語認識システムを実装するために利用した技術について述べる。最初に CTC (Connectionist Temporal Classification), Transformer モデル, Conformer モデルについて述べる。次に、本研究で利用した Hybrid-CTC/Attention について述べる。最後に、本研究でモデルの実装に利用したオープンソースツールである ESPnet2 について述べる。

2.1 CTC (Connectionist Temporal Classification)

本節では、CTC (Connectionist Temporal Classification) [11] について説明する。

一般的に、整備コストの高さから、公開されている音声・環境音データベースには音響信号にアノテーションされた音素やサブワードなどの言語情報のラベルに対応する時間情報が付与されていないことがほとんどである。そのため、音響信号のどのセグメントがどのラベルに対応するのかを考えるアライメント処理が必要であった。CTC は、入力と出力の長さが異なる場合かつ音素やサブワードの境界が不明瞭であっても RNN (Recurrent Neural Network) で直接学習できるモデルとして提案された。

CTC では、音素やサブワードの無いいわゆる無音区間の時間フレームにブランク文字 (.) を導入し、挿入することで入力の時間情報を考慮することが可能である。文字音声認識の文字系列で例えた場合、正解ラベル列が「cat」であるときの、ブランク文字を含むラベル列の例としては以下のようものが挙げられる。

「_c___a__t__」 「_cc_aa__t__」 「_c_aaaaa_d」

ブランク文字 (.) の削除と時間的に連続する同ラベルの集約をすることで結果として正解ラベルを得ることができる。正解系列 l , ブランクを含む系列 π , 入力である音響特徴量を x , ブランク文字や時間的に連続する同ラベルの集約を行う関数を B とした場合、正解系列 l の事後確率を定式化すると式 2.1 となる。

$$p(l|x) = \sum_{\pi \in B^{-1}(l)} p(\pi|x) = \sum_{\pi \in B^{-1}(l)} \prod_{t=1}^T y_{\pi^t}^t \quad (2.1)$$

CTC の最適なパラメータを求める際には、正解系列 l の対数尤度 $\log(p(l|x))$ を最大化する。尤度の計算には、前向き・後向きアルゴリズムを用いる。CTC 損失関数を最大化することで、入力系列である音響信号に対して対応する出力系列（音素やサブワード）がない場合でも、最適なアライメントを自動的に学習し、最終的に正しい出力系列を生成することが可能になる。ここで、CTC 損失とは、式 2.2 で表される。

$$L_{ctc} = -\log(p(l|x)) \quad (2.2)$$

2.2 Transformer モデル

本節では, Transformer モデル [12] について述べる. Transformer は, Attention 機構をベースとした Encoder-Decoder 構造のニューラルネットワークモデルであり, 図 2.1 のようなモデル構造を有している.

図 2.1 の左側の Encoder では, 入力から変換された特徴量ベクトルの系列を出力する. Encoder の Transformer block (図 2.2) は, 1 つの Multi-Head Attention と 1 つの Feed-Forward 層で構成されており, それぞれの層が残差接続 [13] されている. Encoder の Multi-Head Attention では, Self-Attention による Attention 機構が作られている.

図 2.1 の右側の Decoder では, 前出力の特徴量ベクトルと Encoder から得た特徴量ベクトルの類似度を参照することで, 出力系列の次の出力 (音素やサブワード) の予測を行っている. 主に, 2 つの Multi-Head Attention と 1 つの Feed-Forward 層で構成され, それぞれの層が残差接続されている. Decoder の Multi-Head Attention の一方は, マスク処理を加えた Self-Attention, もう一方は, Source-Target Attention が用いられる.

2.2.1 Attention 機構

Attention 機構では, 位置ベクトルが付与された特徴量ベクトル (埋め込みベクトル) の入力から Q (Query), K (Key), V (Value) が求められる. Q は, 入力の各要素が他の要素に対してどれだけ注目すべきか示すベクトルであり, K は, 各要素が持つ特徴を示すベクトルである. V は, 各要素が持つ情報を示すベクトルである. これらを参照して, 入力全体の文脈を考慮した各要素間の関連度を示す Attention 行列として出力する. これを定式化すると式 2.3 で表され, この計算方法を Scaled Dot-Product Attention と呼ぶ. まず, Q と K の内積を求める. 次に, 求めた内積を K の次元数 d_k の平方根で除算し, その値に softmax 関数を適用することで V の重み行列 (Attention 重み行列) を求める. 最後に, 求めた Attention 重み行列と V を乗算し, Attention 行列を求める.

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (2.3)$$

Transformer で主に利用される Attention には 2 種類あり, 図 2.3 で示した. Self-Attention と Source-Target Attention がある.

Self-Attention は, 1 つの入力系列の内部で相互参照することで Q, K, V を求める Attention 機構である. 一方で, Source-Target Attention は, 異なる 2 つの入力から Q, K, V を求めるものである. 入力系列の埋め込みベクトルから Q を求めて, Encoder で出力されたスコアから K, V を求める際に使用される.

Multi-Head Attention は, 複数の head を並列に処理するものである. 図 2.4 に Multi-Head Attention の構造を示す. 系列に含まれる要素間の Attention を多角的に考慮することができるため, 文脈を深く考慮した出力を得ることができる. 式 2.4 で Multi-Head Attention を定式化する. このとき, 各 head は式 2.5 で表され, Attention 機構の入力は QW^Q, KW^K, VW^K である. W は学習可能な重みであり, $W^Q \in \mathbb{R}^{d_{model} \times d_Q}, W^K \in \mathbb{R}^{d_{model} \times d_K}, W^V \in \mathbb{R}^{d_{model} \times d_V}, W^O \in \mathbb{R}^{d_{hdv} \times d_{model}}$ である.




図 2.1: Transformer の構成

$$MultiHead(Q, K, V) = Concat(head_1, head_2, \dots, head_h)W^O \quad (2.4)$$

$$where\ head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (2.5)$$

2.2.2 Feed-Forward 層

Feed-Forward 層は, Multi-Head Attention で得た各 head の出力を均等に結合する役割を持ち, 2つの Linear 層から構成されている. 活性化関数には, 負の値を 0 にして正の値をそのまま保持する ReLU 関数 [14] を利用することが一般的である. Feed-Forward 層への入力を x とする場合, 式 2.6 で定式化する. このとき, W_1, W_2 は学習可能な重み, b_1, b_2 は学習可能なバイアス項である.

$$FFN(x) = max(0, xW_1 + b_1)W_2 + b_2 \quad (2.6)$$




図 2.2: Transformer ブロック




図 2.3: (左)Self-Attention (右)Source-Target Attention

2.3 Conformer モデル

本節では, Conformer モデル [15] について説明する. このモデルは, Transformer モデルの派生の 1 つである. Conformer モデルは Encoder-Decoder 構造を有するが, 特に Encoder の内部構造が特徴的である.

Conformer の Encoder には, 入力の長期的な特徴を受理する Transformer と局所的受容野により入力の局所的な特徴を処理する CNN (Convolution Neural Network) を組み合わせた Conformer ブロックが含まれている. Transformer は Attention 機構を利用した入力全体の関係 (長期的) から特徴を扱うことに長けている一方で, 局所的な特徴を扱うことが苦手であった. また, CNN は畳み込みによる局所的な特徴を捉えることができる一方で, 長期的な特徴を分析する際には, 膨大な計算量が必要となる問題がある. これらの長所を組み合わせることで, 局所的にも長期的にも入力系列の特徴を反映した出力を可能とする.

Conformer の Encoder の構造は, 図 2.5 の左部分となっている. Conformer Blocks までの工程




図 2.4: Multi-Head Attention の構造

では, 入力の前処理を担っている. 前処理を適用したのちの入力に複数の Conformer ブロックを適用することで出力を得ることができる.

2.3.1 Multi-Head Self Attention モジュール

Multi-Head Self Attention モジュールの構造を図 2.6 に示す. このモジュールは, 主に Multi-Head Self Attention 層とドロップアウト層 [16] で構成され, 入力の音響信号の広域的な特徴量を抽出する役割を担っている. Multi-Head Self Attention 層では, 2.2.1 節で説明した Self-Attention のマルチヘッド処理を行う.

2.3.2 Convolution モジュール

Convolution モジュールの構造について, 図 2.7 で示す. このモジュールでは, 入力の音響信号の局所的な特徴量を抽出する役割を担っている.

処理の流れは以下の通りである. まず, 入力に対して Layer Normalization (レイヤー正規化) を適用した後, 最初の Pointwise Convolution 層によってチャンネル方向の特徴量を混合し, ゲート機構である GLU (Gated Linear Unit) [17] を用いて情報の選択を行う. 次に, 活性化関数に Swish 関数を採用した 1D Depthwise Convolution 層を適用することで, 時間軸方向の局所的な特徴抽出を行う. 最後に, 再び Pointwise Convolution 層を通してチャンネル数を調整し, ドロップアウト層を適用して出力を得る. ここで, Pointwise Convolution 層は 1×1 のカーネルを用いてチャ




図 2.5: Conformer の Encoder 構造と Conformer ブロックの構造




図 2.6: Multi-Head Self Attention モジュールの構造

ンネル間の相互作用を計算し、任意の出力次元への調整を行う。一方で、Depthwise Convolution 層は各チャンネルに対して独立に畳み込みを行うことで、計算量を抑えつつ効果的に時間的なコンテキストを捉えることが可能である。

2.3.3 Feed-Forward モジュール

Feed-Forward モジュールでは、入力に正規化を適用後、線形変換と活性化関数である Swish 関数 [18] を適用する。また、過学習を防ぐためにドロップアウトを含めている (図 2.9)。

Swish 関数の計算式は、入力 x 、出力 y として式 2.7 で表され、グラフを図 2.8 で示す。この活性化関数は、線形関数とシグモイド関数を組み合わせたものであるため、非線形性を持ち、複雑なモデル学習を可能とする。

$$y = x\sigma(x) = \frac{x}{1 + e^{-x}} \quad (2.7)$$




図 2.7: Convolution モジュールの構造




図 2.8: Swish 関数のグラフ

2.3.4 Conformer ブロック

Conformer ブロックは、主に 2 つの Feed-Forward モジュールと Multi-Head Self Attention モジュール、Convolution モジュールで構成される (図 2.5 の右部分)。 i 個目の Conformer ブロックへの入力を x_i 、出力を y_i とした各モジュールによる処理は、式 2.8 から式 2.11 で定式化することができる。

$$x'_i = x_i + \frac{1}{2}FFN(x_i) \quad (2.8)$$

$$x''_i = x'_i + MHSA(x'_i) \quad (2.9)$$

$$x'''_i = x''_i + Conv(x''_i) \quad (2.10)$$

$$y_i = Layernorm(x'''_i + \frac{1}{2}FFN(x'''_i)) \quad (2.11)$$

2.4 Hybrid-CTC/Attention モデル

この節では、本研究で採用した Hybrid-CTC/Attention モデル [19] について説明する。Hybrid-CTC/Attention の構造について、図 2.10 で示す。

このモデルは主に、Share Encoder, CTC Decoder, Attention Decoder で構成される。Share Encoder は、入力系列 $x_t, \dots, x_T$ を高次元の特徴量 $h_t, \dots, h_T$ に変換する。変換された特徴量 h を用いて Attention Decoder から出力系列 $c_t, \dots, c_T$ と CTC 損失 L_{ctc} (式 2.12), Attention 損失 L_{att}




図 2.9: Conformer ブロックの FFN モジュール




図 2.10: Hybrid-CTC/Attention の構造 (Share Encoder : Conformer)

(式 2.13) を求めた後, これらを組み合わせた MOL (Multiobjective Learning) により, モデルの最適化を行っている.

最適化によって求められた L_{MOL} は, 式 2.14 に示すように L_{ctc} と L_{att} を線形結合することで求められる. このとき, 重み λ のとりうる値は $0 \leq \lambda \leq 1$ である.

$$L_{ctc} = -\log(p_{ctc}(C|X)) \quad (2.12)$$

$$L_{att} = -\sum_t \log(p_{att}(c_t|X, c_{1:t-1})) \quad (2.13)$$

$$L_{MOL} = \lambda L_{ctc} + (1 - \lambda) L_{att} \quad (2.14)$$

本研究では, Hybrid-CTC/Attention の Share Encoder には, Conformer を採用 (Conformer-Hybrid-CTC/Attention[20]) している. また, MOL の重み λ は $\lambda = 0.3$ とした.

2.5 ESPnet2

本研究では深層学習モデルを構築・評価する際のツールキットとして ESPnet2[21] を使用した。

ESPnet2 は、End-to-End 型の音声認識（ASR: Automatic Speech Recognition）、テキスト音声合成（TTS: Text-to-Speech）等をサポートした音声処理のためのオープンソースソフトウェアである。End-to-End 型モデルを記述するための Python ライブラリ部分と、シェルスクリプトで記述されたレシピ部分で構成されている。

Python ライブラリ部分では PyTorch¹ を深層学習アルゴリズムの記述に利用している。これにより柔軟なモデルの記述と拡張を実現している。

実験の再現性を高めるために、必要な手順をレシピと呼ばれるスクリプトに記述することになっている。本研究でもレシピを記述することで提案手法の実装と実験を行っている。なお、レシピはオープンソースの音声認識ツールキット Kaldi[22] のフォーマットに沿ったものとなる。

2.5.1 モデルの訓練条件

モデルの学習には、レシピを格納したディレクトリ内のスクリプトを実行することになる。本研究で用いた、Encoder と Decoder の学習条件を表 2.1 に示す。その他の諸条件は以下のようにになっている。

- 前処理：default (Log Mel Filterbank (Fbank))
- CTC 損失の重み：0.3
- Attention 損失の重み：0.7
- 言語モデルの学習：True
- サンプリング周波数：16 kHz
- 量子化ビット数：16 bit
- 録音チャンネル数：モノラル (1 ch)
- feats_type：raw
- token_type：char
- FFT サイズ：512 サンプル (32 ms)
- 窓関数長：400 サンプル (25 ms)
- 窓のシフト幅：160 サンプル (10 ms)

2.6 本章のまとめ

本章では、提案手法で採用する深層学習アルゴリズムである Hybrid-CTC/Attention と Hybrid-CTC/Attention の内部処理である CTC, Transformer, Conformer について説明を行った。また、提案手法の実装に用いたツールキットである ESPnet2 について述べ、モデルの学習時に用いたハイパーパラメータの設定等を明らかにした。

実際に深層学習モデルを構築するときは、最適化に用いる学習データの構成が重要となる。次章では、本研究のために整備した学習データの構成を説明する。

¹<https://pytorch.org/>

表 2.1: Hybrid CTC/Attention モデルの学習条件

Encoder		Decoder	
input_layer	conv2d	num_blocks	6
num_blocks	12	linear_units	2048
linear_units	2048		
output_size	256		
attention_heads	4		
activation_type	swish		
use_cnn_module	TRUE		
cnn_module_kernel	15		

第3章 仮説とモデルの学習に使用する連結環境音信号の準備

本章では、これまでに述べた課題の解決のために検討した仮説について述べる。また、その仮説を検証するために実施した実験で使用する深層学習モデルの学習データの作成条件を述べる。はじめに、学習データ作成のために利用した環境音の音響信号のセグメントとそれに紐づいたオノマトペ（テキスト）のデータセットである RWCP-SSD-Onomatopoeia[7] を紹介する。同データセットに含まれる環境音ペアデータを用いて構成した連結環境音信号の作成手順を明らかにする。次に、実験の評価用データには、上記のデータベースとは異なる ESC-50 に含まれる環境音サンプルを使用した。本章では ESC-50 の素性についても述べる。

3.1 RWCP-SSD-Onomatopoeia

RWCP-SSD-Onomatopoeia[7] は、1.2 節で述べた 2 つの関連研究で用いられている。そのため、本研究でも深層学習モデルの学習データである連結環境音信号を作成するために採用した。このデータセットは実環境音音声響データベース (RWCP-SSD[6]) に含まれる 105 種の環境音の音響信号のセグメントに対して、合計 155,568 個のオノマトペ（テキスト）が付与されている。以降、RWCP-SSD-Onomatopoeia の環境音のセグメントとそれに紐づいたオノマトペ（テキスト）を環境音ペアデータと呼ぶことにする。また、擬音語を書き起こした作業者で異なる多様性を考慮するために、1 つの環境音の音響信号のセグメントに対して複数のオノマトペ（テキスト）が付与されている。

3.1.1 自信度と許容度

RWCP-SSD-Onomatopoeia の環境音のセグメントに付与されたオノマトペ（テキスト）には、自信度と許容度という 2 種類の指標が定義されている。

自信度とは、オノマトペを付与した本人自身のオノマトペに対して、どの程度自信があるのかを 5 段階で示した値である。また、自信度は、1 つのオノマトペに対して 1 つ定義されている。ただし、環境音の 1 つのセグメントに対しては、複数の作業者がオノマトペを付与することで、異なる複数のオノマトペの定義が存在している。結果として、1 つの環境音のセグメントには複数のオノマトペと自信度の定義が対応していることになる。一方、許容度とは、自信度 4 以上のオノマトペに対して付与した本人以外の複数人がどの程度許容できるかを 5 段階で示した値である。許容度は、自信度が 4 以上の 1 つのオノマトペに対して複数人による値が示されている。

表 3.1: 上：環境音のセグメントの数
下：付与されたオノマトペの総数

	許容度 4	許容度 4.5	許容度 5
自信度 4	104 (29,349)	96 (7,571)	65 (814)
自信度 5	103 (7,963)	96 (3,431)	41 (479)

3.1.2 データセットの整形

RWCP-SSD-Onomatopoeia の中には、それぞれの環境音ペアデータに対応した.ono ファイルと.acc ファイルが保存されている。 .ono ファイルには、オノマトペを付与した本人の ID, オノマトペ識別 ID, オノマトペ（テキスト）, 自信度が記録されている。 一方, .acc ファイルにはオノマトペ識別 ID, オノマトペ, 許容度を付与した人の ID, 許容度が記録されている。

これらのファイルに記録された注釈に基づいて、自信度と許容度の閾値処理による環境音ペアデータの抽出を行った。 許容度は、1つのオノマトペに対して複数が存在するため、それらの平均の値を閾値処理の際に使用した。 その結果、1つのオノマトペを、1つの自信度と1つの許容度（平均）が一对一对で紐づいた状態として扱うことができるようにした。

環境音ペアデータを抽出する際に使用した閾値の設定には、異なる複数の条件を検討した。 具体的には、許容度（平均）に関しては 4, 4.5, 5 を比較した。 また、自信度は 4, 5 を閾値に用いた。 各条件のときに抽出することができた環境音のセグメントとそれに対応するオノマトペ（テキスト）の数を表 3.1 にまとめる。

3.2 連結環境音信号の作成方法

本研究では、前述のように抽出した環境音のセグメントを時間方向につなげた連結環境音信号を深層学習モデルの学習に用いた。 その連結の際に、対応するオノマトペ（テキスト）を参照することで、無作為型（図 3.1）と反復型（図 3.2）の連結信号を準備している。 なお、この処理の際、乱数によって連結対象となる環境音のセグメントを選択しているが、実験の再現性を確保するため、乱数シードを固定した Python のオリジナルプログラムを使用している。 このとき、連結対象とする環境音のセグメントに対応するオノマトペの重複は許している。 ただし、同時に複数の連結信号を作成する場合に、オノマトペの連結ラベルが全く同じにならないように生成した。

- 無作為型は、図 3.1 のように、環境音ペアデータをランダムに選択し、10 個を時間方向に連結した場合の連結環境音信号である。
- 反復型は、図 3.2 のように、ランダムに選択した環境音ペアデータの 2 個をセットとし、そのセットを単位として 5 回繰り返すことで時間方向に連結した連結環境音信号である。




図 3.1: 無作為型の連結例




図 3.2: 反復型の連結例

3.3 評価用環境音サンプル ESC-50

学習したモデルの評価データとして、学習データに含んでいない未知の環境音サンプルである ESC-50 を用いた。ESC-50 は、環境音ベンチマークに適した 2,000 件のラベル付き環境音データセットである。付与されているラベルは環境音サンプルを分類するためのイベントラベルのみであり、擬音語ラベル（テキスト）は付与されていない。そのため、一般的に環境音を分類するときに利用されることが多い。また、各環境音サンプルは 5 秒間の収録信号となっている。

ただし、本研究では ESC-50 に含まれる Interior/domestic sounds カテゴリの環境音サンプルのみを抽出して使用した。これは、モデルの学習データである RWCP-SSD-Onomatopoeia には、木材や金属などを叩く音やベルやアラームの音等で構成されているためである。モデルの学習と評価に用いる環境音サンプルの発生要因がまったく異なる場合、その特徴も完全に異なったものとなるため認識処理が成立しない恐れがある。よって比較的、同様な特徴を有すると考えられる Interior/domestic sounds カテゴリのサンプルを評価に用いることにした。なお、このカテゴリのデータセットは、10 クラスの環境音サンプルで構成されており、1 クラス 40 個ずつの計 400 個の環境音サンプルが含まれている。

3.3.1 クラスの分類

同一のクラスに属する環境音であっても、その波形的特徴は必ずしも一様ではない。そのため、主観評価の結果を比較・考察する際、すべてのラベルを「認識結果への影響」という観点で同列に扱うことは困難である。

そこで本研究では、各クラスの音響信号が発生する事象に由来する、時間軸方向での音響的特徴を考慮した新たな区分を定義した。具体的には、ESC-50 の Interior/domestic sounds に含まれる

10 クラスを, 時間的な連続性や定常性といった音響的類似性に基づき, 以下の 3 つのカテゴリに分類した.

- 瞬発性のある環境音: 「缶を開ける音」「ガラスが割れる音」
- 持続性のある環境音: 「ドアがきしむ音」「洗濯機の音」「掃除機の音」
- 反復性のある環境音: 「時計のアラーム音」「ドアのノック音」「タイピング音」「マウスのクリック音」「時計の針の音」

3.4 本研究の仮説

1.2 節で述べたように, 本研究では, 先行研究 [10] で示された検討事項の解決を目的として, 異なる観点での 3 つの仮説を策定し, 各仮説に基づいた比較実験による検証を行った. 以下にその 3 つの仮説を示す.

- 仮説 1: あえて種類を減らした擬音語をランダムに連結して繰り返しパターンを表現できる
擬音語の多様性を意図的に制限した上で, モデルによる典型的な繰り返しパターンの学習を促すことができると仮定した. 先行研究では, 「自信度 4 以上・許容度 4 以上」の環境音のセグメント 104 種とそれに対応するオノマトペ 29,349 個を用いて, 連結環境音信号を作成していた. 本研究では, 「自信度 4 以上・許容度 4.5 以上」のように制限を強め, 使用する環境音のセグメント 96 種とそれに対応するオノマトペ 7,571 個に削減し, 連結環境音信号を作成した.
- 仮説 2: 反復型をモデルの学習に含めないことで不自然な繰り返しの出力を抑制できる
学習データに無作為型のみを利用することで, モデルが出力する結果に繰り返しパターンが出現する頻度が少なくなるため, 結果として, 不自然な繰り返しの出力を抑制できると仮定した.
- 仮説 3: 無作為型のみで学習データを準備し, モデルの学習に使用する数を増やすことで繰り返しパターンを表現できる
単純な学習データの増加により, その一部に繰り返しパターンを含んだ連結環境音信号が内包されるようになり, 結果として, モデルが繰り返しパターンを受理できるようになると考えた.

3.5 予備実験 (モデルの学習に使用するデータ数の検討)

本研究の実験では, 前述の仮説に基づいた比較実験を行う. その際に使用する学習データの数を決定するために認識性能の予備実験を行った. 学習データの数を変更した複数の条件で擬音語の認識実験を行った. 予備実験であるため, この際の評価 (認識結果の妥当性あり・なし) の基準は, 著者一人の主観とした.




図 3.3: 予備実験結果（「○」のみ、横軸：学習データの数、縦軸：妥当率 [%]）




図 3.4: 予備実験結果（「○」と「△」、横軸：学習データの数、縦軸：妥当率 [%]）

仮説 1 から仮説 3 を検討するために、「自信度 4 以上・許容度 4.5 以上」の環境音を利用した無作為型のみの連結環境音信号を含めて、モデルの学習データとした。使用した学習データは、30,000, 45,000, 60,000, 75,000, 90,000, 120,000 の 6 つの条件とした。

主観による評価の実施に際して、本研究の擬音語（オノマトペ）を「物音などを模倣し、その音を表現した言葉」としている。この定義に基づいて主観によって、「○, △, ×」の 3 段階の評価を行った。主観による評価の基準を以下に示す。

- ○：出力は入力 of 擬音語として納得できる
- △：出力は入力 of 擬音語ではなく、文字起こし結果である
- ×：出力は入力 of 擬音語や文字起こし結果とは異なる

評価用の環境音サンプルは、前述のように ESC-50 の Interior/domestic sounds カテゴリの環境音のうち、「時計のアラームの音」、「缶を開ける音」、「ドアのノック音」、「ドアがきしむ音」、「ガラスが割れる音」の計 50 個を用いた（各 10 サンプル）。

図 3.3, 図 3.4 に予備実験の評価結果を示す。各棒グラフの縦軸は妥当率を表し、横軸はモデルの学習に用いた無作為型で構成する連結環境音信号の数を表す。ここで妥当率とは、「○」と評価し

た数, または「○」と評価した数と「△」と評価した数の合計を各クラスの評価データの数で除算したときの割合である。

「○」のみの妥当率 (図 3.3) に注目すると, 一部のクラスでは認識精度の向上はなかった。しかし, 全体の平均では, 無作為型のみ 12 万個の連結環境音信号を用いたときに最も高い精度を示した。

「○」と「△」のみの妥当率 (図 3.4) では, モデルの学習に用いた連結環境音信号の数を 3 万から 12 万まで増やすことで, 妥当率における緩やかな向上傾向がある。すべてのクラスの平均では, 学習データの数が増えるときにもっとも高い値となった。

3.6 本実験で利用した学習データ作成条件

予備実験の結果を踏まえて, 3.4 節で述べた仮説について検証できるように, 深層学習モデルの学習に使用する学習データの作成条件を決定した。条件は 4 つとし, 各条件の構成を表 3.2 に示す。

条件 1, 条件 2, 条件 3 は, 「自信度 4 以上・許容度 4.5 以上」の環境音ペアデータを用いて連結環境音信号を作成した。条件 1 では, 30,000 個の無作為型のみで構成する。条件 2 は, 同じく無作為型のみであり, 3.5 節の予備実験結果を考慮して, その数を 120,000 個に増やしたものである。条件 3 は, 無作為型 24,000 個と反復型 6,000 個の連結環境音信号が混在するものである。この無作為型と反復型の比率は, 先行研究 [10] において, もっとも高い性能を示した条件である反復型 20%を参考にして決定した。また, 条件 4 は, 先行研究 [10] のときと同条件の連結環境音信号をモデルの学習に用いるものとなっている。先行研究 [10] では, 本研究の仮説 1 で述べた使用する環境音の制限を行っていない。そのため, 仮説 1 を適用した本研究の条件 1～条件 3 とは異なり, 使用する環境音ペアデータの「自信度は 4 以上・許容度 4 以上」と多様性は高くなっている。モデルの学習に使用した量的な条件では, 無作為型 24,000 個, 反復型 6,000 個であり条件 3 と同じ反復型 20%である。

表 3.2: 実験で比較したモデルの学習条件 (4 条件)

	学習データ数 [個]	閾値 自信度/許容度	無作為型 [%]	反復型 [%]
条件 1	30,000	4/4.5	100	0
条件 2	120,000	4/4.5	100	0
条件 3	30,000	4/4.5	80	20
条件 4 (先行研究 [10])	30,000	4/4	80	20

仮説 1 は条件 3 と条件 4, 仮説 2 は条件 1 と条件 3, 仮説 3 は条件 1 と条件 2 のときの認識性能を比較することで検証することができる。

3.7 本章のまとめ

本章では, 本研究で検証する 3 つの仮説について述べた。次章では, その仮説を実験によって比較検証する。次章の実験で使用する深層学習モデルの学習データの数を決めるために実施した予

備実験の結果について整理した。環境音のセグメントに対応するオノマトペの自信度と許容度の閾値, 連結環境音信号に含まれる無作為型の割合によって異なる学習データの4条件を決定した。

第4章 主観評価による仮説の検証

本章では、3.4 節で述べた本研究の仮説を検証するために行った実験とその結果について述べる。3.6 節で述べた異なる条件で作成した深層学習モデルの出力に対して、人の主観によってその妥当性を調査した。

4.1 主観評価実験の方法

主観評価に先立って、3.3 節で述べた評価用の環境音サンプル 50 個を 4 条件で作成した擬音語認識の深層学習モデルに入力し、出力結果（テキスト系列）を得た。実験協力者が評価用環境音サンプルを聴取するとともに、出力結果を目視によって確認し、その結果を妥当性を判断する主観による評価を行った。実験協力者は、日本語を母国語とする男性 12 名、女性 3 名の計 15 名の学生である。この実験は、Google フォームを利用したウェブアンケート形式で行った。図 4.1 で評価実験で用いた Google フォームの一部分を示す。

実験の手順を示す。まず、実験協力者は入力用の環境音サンプルを聴取する。このとき、モデルの入力に使用した環境音サンプル 50 個が 5 秒間隔で連続再生する動画ファイルを提供し、協力者は、各自の PC 上で評価用環境音サンプルを聴取できるようにした。提供した動画ファイルはモデルごとに別で作成しており、同じ 50 個の環境音サンプルが異なる順番で再生されるようになっている。次に、以下の 2 つの質問に対する回答を○または×の 2 件法によって回答することを求めた。

- 質問 1：環境音に対してテキストは音を忠実に書き起こしとしたものとして正しい
- 質問 2：環境音から想像できるテキストとして妥当である

ここで「テキスト」としているのは、協力者に提示した深層学習モデルの出力（認識結果）である。つまり、協力者は、音を聞いた後、その音に対応しているテキストを目視して、○または×を回答することになる。この行為を評価用の環境音サンプル 200 個に対して繰り返して行った。

なお、質問 1 は、聴取した評価用の環境音サンプルに対して、提示されたテキスト（認識結果）がシンプルに文字起こしたものとして妥当であるかを問うものである。質問 2 は、3.5 で述べた本研究での擬音語（オノマトペ）の定義「物音などを模倣し、その音を表現した言葉」としての妥当性を問うものである。主観に基づくため、この回答には、協力者の出身などによる文化的な前提が影響すると考えられる。今回は、日本出身で年齢層も同じである学生を協力者として統一することで、文化的な影響をある程度は抑えることができていると考える。

4.2 主観評価実験の結果と考察

本節では、実験の結果を報告する。各質問に対して、協力者が「○」と回答した数を環境音の環境音サンプル単位で集計する。その合計を提示した環境音サンプルの数で除算したものを妥当率

表 4.1: 質問 1：クラス別の妥当率 [%] の平均
(「○ (妥当)」と回答した数/回答者数)

環境音のクラス	条件 1	条件 2	条件 3	条件 4
缶を開ける音	29.3	38.7	29.3	29.3
ガラスが割れる音	32.0	30.7	18.7	9.3
ドアがきしむ音	20.0	12.0	12.0	17.3
洗濯機の音	20.0	26.7	28.0	5.3
掃除機の音	41.3	57.3	45.3	49.3
時計のアラーム音	45.3	37.3	42.7	61.3
タイピング音	34.7	13.3	29.3	42.7
ドアのノック音	49.3	36.0	36.0	58.7
マウスのクリック音	32.0	13.3	12.0	9.3
時計の針の音	16.0	14.7	32.0	24.0
平均	32.0	28.0	28.5	30.7

表 4.2: 質問 2：クラス別の妥当率 [%] の平均
(「○ (妥当)」と回答した数/回答者数)

環境音のクラス	条件 1	条件 2	条件 3	条件 4
缶を開ける音	38.7	28.0	25.3	28.0
ガラスが割れる音	30.7	38.7	22.7	6.7
ドアがきしむ音	14.7	8.0	17.3	13.3
洗濯機の音	28.0	33.3	33.3	16.0
掃除機の音	56.0	61.3	64.0	66.7
時計のアラーム音	57.3	46.7	56.0	72.0
タイピング音	34.7	13.3	44.0	42.7
ドアのノック音	46.7	50.7	28.0	70.7
マウスのクリック音	28.0	17.3	16.0	18.7
時計の針の音	32.0	22.7	38.7	28.0
全体平均	36.7	32.0	34.5	36.3

として求めた。

表 4.1 (質問 1：忠実な書き起こし) と表 4.2 (質問 2: 擬音語として妥当) にクラス単位の妥当率の平均を示す。また、3.3.1 節で述べた環境音のカテゴリに関する考察についても後述する。

図 4.2, 図 4.3, 図 4.4 に、各仮説に関する比較結果を示す。これらの図は、各仮説に関する比較条件の妥当率をクラス別に示したものである。横軸が環境音のクラスを表し、縦軸がクラス単位の妥当率の平均 [%] を表す。また、エラーバーは標準誤差を示している。

4.2.1 仮説1（条件3と条件4）の比較結果

仮説1では、先行研究（条件4）で用いられた「自信度4以上・許容度4以上」の環境音ペアデータに対し、本研究では「許容度の平均」を厳格化（平均4.5以上）することで擬音語の多様性を意図的に制限した。これにより、モデルが典型的な繰り返しパターンを学習し、出力性能が向上することを期待した。仮説1の結果の比較を図4.2で示す。

質問1および質問2のいずれにおいても、全クラス平均の妥当率は条件4（多様性あり）が条件3（制限あり）を上回る結果となった。具体的には、質問2におけるすべてのクラスの妥当率の平均は、条件4の36.3%に対し、条件3は34.5%であった。しかし、音の性質ごとに分析すると異なる傾向が見られた。瞬発性のある環境音では、質問1において条件3が条件4と同等以上の妥当率を示した。特に持続性のある環境音においてはこの傾向が顕著であり、質問2では条件4よりも条件3の方が妥当率が高くなる傾向が確認された。一方で、反復性のある環境音については、5クラス中3クラスで条件4の方が高い妥当率を示し、特に「ドアのノック音」では条件4が70.7%であったのに対し、条件3は28.0%と大幅に下回る結果となった。

多様性の制限は、持続性のある環境音における「ジー」「ズー」「ゴー」といった特定の擬音語が一定時間継続して出力されるケースにおいて、許容度の高い語が選ばれやすくなるため、性能向上に寄与したと考えられる。一方で、反復性のある環境音や瞬発性のある環境音においては、本来多様な擬音語の表現が可能であるため、選択肢を制限したことによる悪影響が上回り、実際の聴取印象と認識結果の乖離を招いたと推察される。

4.2.2 仮説2（条件1と条件3）の比較結果

仮説2では、あえて反復型を学習から除外することで、認識性能を維持しつつ不自然な繰り返しの出力を抑制できるかを検証した。仮説2の結果の比較を図4.3で示す。

質問1において、条件1（無作為型のみ）の全てのクラスの妥当率の平均は32.0%となり、全条件の中で最も高い値を示した。3.3.1節で述べたカテゴリで考えると、瞬発性のある環境音および持続性のある環境音において条件3（反復型混合）よりも高い妥当率が得られた。質問2においても、瞬発性のある環境音は条件1の方が高く、全5クラス中3クラスで条件1が条件3を上回った。特に「マウスのクリック音」では、条件3の16.0%に対し、条件1は28.0%と有意な向上が見られ、「ドアのノック音」においても条件1（46.7%）が条件3（28.0%）を大きく上回った。

先行研究[10]では瞬発音における不自然な繰り返しが課題であったが、反復型を利用しない（条件1）ことで、これらの認識性能が向上することが確認された。また、多様性を制限した上で無作為型のみを用いて学習することで、モデルが反復を含む環境音を適切に受理・表現できる可能性が示唆された。特に、反復性のある環境音の中でも、人為的に発生する音である「ドアのノック音」と「マウスのクリック音」は不規則なリズムで似た音が連続する環境音であるため、無作為型のみ（条件1）で学習したモデルの認識結果が良好であったと考えられる。ただし、すべてのクラス（持続性のある環境音や機械的なリズムが一定の反復性のある環境音）で条件1が優位だったわけではないため、今後は反復型の完全な除外ではなく、選別や利用方法にさらなる工夫が必要である。また、環境音の特性に合わせたモデルを構築することも有効であると考えられる。

4.2.3 仮説3（条件1と条件2）の比較結果

仮説3では、無作為型を3万個（条件1）から12万個（条件2）へ増やすことで、反復型を頼らずとも環境音の中の繰り返しパターンを学習できると考えた。仮説3の検証結果を図4.4に示す。

全クラス平均の妥当率では、質問1・質問2のいずれも条件1（3万個）が条件2（12万個）を上回る結果となった。具体的には、質問1「忠実な書き起こし」の平均は条件1が32.0%に対し条件2は28.0%、質問2「擬音語として妥当」では条件1が36.7%に対し条件2は32.0%であった。詳細を見ると、瞬発性のある環境音や持続性のある環境音（「掃除機の声」など）については条件2で性能向上の兆しが見られたものの、反復性のある環境音については、ほぼすべてのクラスで条件1の方が高い妥当率となった。特に「タイピング音」の質問2「擬音語として妥当」では、条件1の34.7%に対し条件2は13.3%と大きく妥当率が低下していた。

深層学習モデルの学習に使用したデータの数を増加させたことにより、相対的に「非現実的な組み合わせ」の連結環境音信号が増加したことが要因と考えられる。これによりモデルの学習が複雑化し、特にリズム感が重要となる反復性のある環境音において、適切な書き起こしや擬音語の生成を妨げ、認識性能の低下を招いた恐れがある。

4.2.4 質問1と質問2の「○」回答数の比較

「質問1：環境音に対してテキストは音を忠実に書き起こしとしたものとして正しい」と「質問2：環境音から想像できるテキストとして妥当である」に対して、ここでは、各環境音サンプルごとに質問1と質問2の「○」の回答数の差（質問2－質問1）を求めた。結果を図4.3に示す。全体として、質問1よりも質問2の方が「○（妥当）」の回答数が多くなる傾向が見られた。この差が3以上（回答者15名中20%以上の開き）あったクラスは、「時計のアラーム音」「ドアのロック音」「時計の針の音」「掃除機の声」など、特に反復性のある環境音に集中していた。これは、人間の擬音語に対する許容範囲が、厳密な音の書き起こしに比べて広いことを示唆している。認識結果のテキストが、環境音の聴取から連想的に想像できるような表現となっており、厳密な正確性が損なわれている場合や繰り返しパターンの再現が十分になされていない場合、文字列上の表現の曖昧性が残っている場合であっても、人は「擬音語として許容できる」と判断する傾向があると確認できる。

4.2.5 実際の出力例

今回の実験で確認できた認識結果（出力テキスト）の具体的な事例を示す。また、この事例に対する質問1「忠実な書き起こし」と質問2「擬音語として妥当」の「○」の回答数を表4.4に示す。

- 条件1（多様性の制限、無作為型のみ、3万個）： ピピピピピーピーピピピピピピピー
- 条件2（多様性の制限、無作為型のみ、12万個）： ピピピピリンリンピピピピリンリーンピピピピ
- 条件3（多様性の制限、反復型混合、3万個）： ピッピッピッピッピッピッピッピッピッピッピッ
- 条件4（反復型混合、3万個）： ピピピピピピピ

すべての条件において時計のアラーム音から想像できる「ピ」が連続していることが分かる。条件3と条件4はモデルの学習に反復型の連結環境音信号を含んでいるため「ピッ」や「ピ」が交互に連続している。その結果、主観評価による「○」の回答数が多くなっている。一方で、条件1（無作為型のみ、3万個）では出力テキストが条件3・4に比べてリズム感（繰り返しパターンの出現）に欠如が生じているように思われるが、質問2「擬音語として妥当」では、15人中12人が「○」と回答しており、大多数にとって擬音語として許容されていることが分かる。また、表4.4のどの条件においても、質問1より質問2の方が「○」の回答数が多いことも人の許容性の高さを示したもののになっている。

次に示す事例は「タイピングの音」によるものである。同様に、この事例に対する質問1「忠実な書き起こし」と質問2「擬音語として妥当」の「○」の回答数を表4.5に示す。

- 条件1（多様性の制限、無作為型のみ、3万個）： カタッタッタッタッタッタカラカタッタッタ
タツカラカチャーカツカラカラ
- 条件2（多様性の制限、無作為型のみ、12万個）： カンチンコロカラカラカラカラカラカラ
ラカラカラカラシャッカタラカラカンカラ
- 条件3（多様性の制限、反復型混合、3万個）： カカタカタタカタカタカタカタカタカタカタ
カタカタカタカタカタカタカタカタカタカタカタカタカタカタ
- 条件4（反復型混合、3万個）： タツタカタタタタタタタタタタタタタタタタタタタタタ
タタ

質問1「忠実な書き起こし」の回答では、条件3が最も高く、条件4が次点となった。質問2「擬音語として妥当」では、条件1と条件3ではすべての協力者から「○」の回答を得ている。3.3.1節で定義したカテゴリでは「タイピングの音」を反復性のある環境音としているが、タイピングは厳密に言えばリズムは一定ではなく、不規則なリズムで音響的に似た特徴の信号が連続することになる。そのため、妥当性の判断を人の主観に頼る本実験においては、条件1は、不規則ながらも似た音の連続の出力に成功しているため、擬音語として妥当であると判断された可能性が高いと考える。

4.3 本章のまとめ

本章では、本研究で設定した仮説1から仮説3までの検証を協力者15名による主観評価（2件法）によって行った。実験の結果、質問1「忠実な書き起こし」・質問2「擬音語として妥当」のどちらにおいても、条件1で学習したモデルの妥当率が最も高く、環境音の多様性を制限し、無作為型のみでモデルを学習した場合でも繰り返しパターンの再現は可能であり、擬音語認識の総合的な能力としては高い性能を示すことがわかった。しかし、仮説2の検証において、一部の繰り返しパターンを含む環境音に限れば、反復型を学習に含んだ場合の方が高い妥当率を示した。このため、無条件に先行研究[10]の性能を維持できるとは言えない。また、質問2「擬音語として妥当」の方が質問1「忠実な書き起こし」よりもポジティブな回答が得られることが確認できた。この結果からは、擬音語認識システムが書き起こしのような忠実な認識結果を出力できない場合であっても、人は、それを擬音語として許容できる可能性が高いことが考えられる。

Section1(1~50)
<https://youtu.be/jZGHTV7UUdA>



1: ドーン

環境音に対してテキストは音を忠実に書き起こしとしたものとして正しい *

☐ ○ ☐ ○

☐ ○ ☐ ×

環境音から想像できるテキストとして妥当である *

☐ ○ ☐ ○

☐ ○ ☐ ×

図 4.1: 評価実験で利用した Google フォーム





図 4.2: 実験結果：仮説 1（多様性の制限）に関する比較（左：質問 1「忠実な書き起こし」、右：質問 2「擬音語として妥当」）





図 4.3: 実験結果：仮説 2（無作為型のみ）に関する比較（左：質問 1「忠実な書き起こし」、右：質問 2「擬音語として妥当」）





図 4.4: 実験結果：仮説 3（データ量の増大）に関する比較（左：質問 1「忠実な書き起こし」、右：質問 2「擬音語として妥当」）

表 4.3: 質問 1「忠実な書き起こし」と質問 2「擬音語として妥当」の回答「○」の数の差（質問 2-質問 1）

	条件1	条件2	条件3	条件4
時計の針の音	1	-1	2	-1
	1	0	1	2
	4	1	5	4
	3	4	2	2
	0	3	0	1
缶を開ける音	3	-1	0	-2
	0	2	0	0
	1	-7	-1	-2
	2	-1	1	0
	1	-1	-3	3
ドアのノック音	-1	3	1	0
	1	2	0	3
	-1	0	3	0
	1	2	0	3
	-2	4	4	3
ドアのきしむ音	-1	-1	1	0
	0	-1	-1	0
	-1	0	0	0
	-1	0	1	-1
	-1	-1	3	-2
ガラスが割れる音	-2	0	0	0
	-1	1	2	0
	2	-2	0	-1
	1	3	1	-1
	-1	4	0	0
タイピング音	0	1	1	0
	-1	0	3	1
	0	0	3	-1
	-3	-2	3	0
	4	1	1	0
洗濯機の音	2	1	3	5
	2	0	0	0
	2	1	-1	0
	1	3	1	0
	-1	0	1	3
マウスのクリック音	-2	-2	-3	4
	1	2	2	0
	0	0	0	1
	-2	0	2	1
	0	3	2	1
時計の針の音	3	2	3	-1
	5	3	1	0
	3	0	1	3
	1	1	1	2
	0	0	-1	-1
掃除機の音	4	0	0	0
	2	0	3	4
	1	3	4	2
	1	2	5	2
	3	-2	2	5

表 4.4: 事例「時計のアラーム音」に対する「○」の回答数

	条件 1	条件 2	条件 3	条件 4
質問 1	8	5	10	10
質問 2	12	6	15	14

表 4.5: 事例「タイピング音」に対する「○」の回答数

	条件 1	条件 2	条件 3	条件 4
質問 1	11	5	14	12
質問 2	15	6	15	12

第5章 おわりに

5.1 まとめ

本研究では、先行研究 [10] で課題となった繰り返しパターンを含まない環境音の音響信号を入力としたときの出力に、本来存在しない繰り返しパターンが生じることを抑制するために検討を行った。その過程において、擬音語の多様性の制限、反復型の除外、および無作為型の増加の3つの仮説に基づき、4つの条件で深層学習モデルを構築・比較した。

15名の協力者による主観による認識結果（出力テキスト）の妥当性を調査した。その結果、擬音語の多様性の制限（許容度の平均4.5以上）をして無作為型のみを3万個で学習したモデルの出力性能は、反復性のある環境音に対しても高い擬音語認識性能を示す妥当性を確認した。しかし、一部の反復性のある環境音に対する擬音語認識性能は依然として、モデルの学習に反復型を含めた場合の方が高くなることが分かった。また、この実験からは、人が感じる擬音語としての妥当性には広い許容性があることが示された。

5.2 今後の課題

本研究で扱った擬音語認識の技術的な確立には依然としてさまざまなレベルの課題が残されていると考える。以下に、その中から主なものを述べる。

- 事後確率の閾値の導入

Hybrid-CTC/Attention モデルの推論では、各時刻 t において argmax 関数を適用し、事後確率が最大のトークンを出力する。しかし、入力信号に目的音以外の背景雑音が含まれる場合、モデルがそれらの雑音に対しても何らかの文字を割り当ててしまう「過検出」の懸念がある。これに対し、事後確率に閾値を設定し、全候補の確率が閾値を下回る時刻 t においては出力を棄却（空文字を割り当て）する手法が有効であると考えられる。これにより、ノイズに起因する不必要な出力を抑制し、認識精度の向上に寄与する可能性がある。今後は、適切な閾値の設定方法および、それがオノマトペ生成の妥当性に与える影響について詳細に検証する必要がある。

- 擬音語の言語モデル導入の検討

現状、モデルの学習に用いる連結環境音信号の作成には、ランダムな環境音セグメントの選択が行われている。しかし、本来ならば、環境音セグメントの並びでは、コンテキストによる言語情報のようなものを考慮する必要があると考える。このためには、音声認識でいうところの言語モデルの導入が必要であると考えられる。擬音語（オノマトペ）の言語モデルの定義を含めて、現実的な実装を検討する必要がある。

- 擬音語認識システムのアプリケーション化

提案手法を社会実装し, 広く有効性を示す必要があると考える. そのためには, 擬音語をテキストに変換する機能を応用したアプリケーションの開発が必要であると考えている.

謝 辞

本論文の作成にあたり，本研究のテーマから実験の実施まで終始適切な助言を賜り，丁寧に指導してくださった西村竜一先生に心より感謝申し上げます．また，本研究にご理解とご協力を賜りましたメディアインテリジェンス研究室の皆様に深く感謝し，御礼申し上げます．

発表リスト

- 森山颯太, 西村竜一, 主観による適合率を尺度とした E2E 型擬音語認識手法の性能比較, 第 61 回関西合同音声ゼミ, ポスター発表, 奈良先端科学技術大学院大学 ミレニアムホール, 2025.
- 森山颯太, 西村竜一, E2E 型擬音語認識において無作為に連結したデータで環境音の”繰り返し”を学べるか, 日本音響学会第 28 回関西支部若手研究者交流研究発表会, ポスター発表, 京都大学 吉田キャンパス, 2025.
- 森山颯太, 西村竜一, 無作為連結環境音をモデル学習に用いた E2E 型擬音語認識の性能評価, 日本音響学会第 155 回 (2026 年春季) 研究発表会講演論文集, 3-Q-7, 2026.

参考文献

- [1] Y. Okamoto, K. Imoto, S. Takamichi, R. Yamanishi, T. Fukumori, and Y. Yamashita, Onomatowave: A Generative Model for Onomatopoeic Words Based on Environmental Sound Synthesis, *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, Vol. 29, pp. 2411-2424, 2021.
- [2] I. Sutskever, O. Vinyals, and Q. V. Le, Sequence to Sequence Learning with Neural Networks, *Proc. Advances in Neural Information Processing Systems (NeurIPS)*, pp. 3104-3112, 2014.
- [3] A. Graves and J. Schmidhuber, Framewise phoneme classification with bidirectional LSTM and other neural network architectures, *Neural Networks*, Vol. 18, No. 5-6, pp. 602-610, 2005.
- [4] S. Hochreiter and J. Schmidhuber, Long short-term memory, *Neural Computation*, Vol. 9, No. 8, pp. 1735-1780, 1997.
- [5] D. Griffin and J. Lim, Signal estimation from modified short-time Fourier transform, *IEEE Transactions on Acoustics, Speech, and Signal Processing*, Vol. 32, No. 2, pp. 236-243, 1984.
- [6] S. Nakamura, K. Hiyané, F. Asano, T. Nishiura, and T. Yamada, Acoustical sound database in real environments for sound scene understanding and hands-free speech recognition, *Proc. LREC*, pp.965-968, May. 2000.
- [7] Y. Okamoto, K. Imoto, S. Takamichi, R. Yamanishi, T. Fukumori, and Y. Yamashita, RWCP-SSD-Onomatopoeia: Onomatopoeic Word Dataset for Environmental Sound Synthesis, *Proc. Detection and Classification of Acoustic Scenes and Events (DCASE)*, pp.125-129, 2020.
- [8] Karol J. Piczak, ESC: Dataset for Environmental Sound Classification, *Proc. ACM Conference on Multimedia*, pp. 1015-1018, 2015.
- [9] 石原 一志, 駒谷 和範, 尾形 哲也, 奥乃 博, 環境音を対象とした擬音語自動認識 擬音語表現における音素決定曖昧性の解消, *人工知能学会論文誌*, vol. 20, no. 3, pp. 229-236, 2005.
- [10] 松浪 優斗, 西村 竜一, 反復した環境音の学習による擬音語認識システムの開発, *日本音響学会第 153 回 (2025 年春季) 研究発表会講演論文集*, pp.989-990 , 2025.
- [11] Alex Graves, Santiago Fernandez, Faustino Gomez, Jurgen Schmidhuber, Connectionist Temporal Classification: Labelling Unsegmented Sequence Data with Recurrent Neural Networks, *Proc. of the 23rd International Conference on Machine Learning (ICML '06)*, pp. 369-376, 2006.
- [12] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, Illia Polosukhin, Attention Is All You Need, *arXiv:1706.03762*, 2017.

- [13] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun, Deep Residual Learning for Image Recognition, arXiv:1512.03385, 2015.
- [14] Nair V. and Hinton G. E., Rectified Linear Units Improve Restricted Boltzmann Machines, Proc. International Conference on Machine Learning, pp.807-814, 2010.
- [15] Anmol Gulati, James Qin, Chung-Cheng Chiu, Niki Parmar, Yu Zhang, Jiahui Yu, Wei Han, Shibo Wang, Zhengdong Zhang, Yonghui Wu, Ruoming Pang, Conformer: Convolution-augmented Transformer for Speech Recognition, Proc. Interspeech 2020, 2020, p. 5036-5040.
- [16] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, Ruslan Salakhutdinov, Dropout: A Simple Way to Prevent Neural Networks from Overfitting, Journal of Machine Learning Research, Vol. 15, pp. 1929-1958, 2014.
- [17] Yann N. Dauphin, Angela Fan, Michael Auli, David Grangier, Language Modeling with Gated Convolutional Networks, arXiv:1612.08083, 2016.
- [18] Prajit Ramachandran, Barret Zoph, Quoc V. Le, Swish: a Self-Gated Activation Function, arXiv:1710.05941, 2017.
- [19] S. Watanabe, T. Hori, S. Karita, T. Hayashi, J. Nishitoba, Y. Unno, N. Fukuda, J. Yamamoto, T. Ochiai, W. Chan, Y. Zhang, R. A. Yeh, M. L. Seltzer, and Y. Bengio, Hybrid CTC/Attention Architecture for End-to-End Speech Recognition, IEEE Journal of Selected Topics in Signal Processing, Vol. 11, No. 8, pp. 1240-1253, 2017.
- [20] Pingchuan Ma, Stavros Petridis, Maja Pantic, End-to-End Audiovisual Speech Recognition with Conformer, Proc. Interspeech, pp. 1612-1616, 2021.
- [21] S. Watanabe, T. Hori, S. Karita, T. Hayashi, J. Nishitoba, Y. Unno, N. Fukuda, J. Yamamoto, T. Ochiai, W. Chan, Y. Zhang, R. A. Yeh, M. L. Seltzer, and Y. Bengio, ESPnet: end-to-end speech processing toolkit, Proc. Interspeech, pp. 2207-2211, 2018.
- [22] D. Povey, A. Ghoshal, G. Boulianne, L. Burget, O. Glembek, N. Goel, M. Hannemann, P. Motlicek, Y. Qian, P. Schwarz, J. Silovsky, G. Stemmer, and K. Veselov, The Kaldi Speech Recognition Toolkit, Proc. IEEE 2011 Workshop on Automatic Speech Recognition and Understanding (ASRU), pp. 1-4, 2011.