

擬音語認識モデルの学習のための連結環境音の構成法

メディアインテリジェンス研究室 60276266 森山 颯太

研究背景・目的

- Hybrid-CTC/Attentionモデルを用いた擬音認識システム
入力：環境音 出力：オノマトベに近いテキスト
最終的な利用先：映画・アニメへの効果音の字幕付与など

● 先行研究[1]

- 無作為型と反復型を混合した訓練データを用いた擬音語認識モデル
→ 擬音語認識の出力（文字列）にリズム感を再現
- 反復型の含有率別の認識結果に対する主観評価による適合率の比較
→ 含有率20%が妥当

- 問題点(先行研究[1]): 認識結果に不自然な反復パターンを確認

- モデルの訓練データに反復型を含むとき
- 入力（認識対象）が反復パターンを含まないとき

● 研究目的


- 繰り返しを含む入力に対しては、認識性能を維持（先行研究[1]）
 - 繰り返しを含まない入力に対しては、不自然な繰り返しの出現を抑制
- 1, 2を1つの深層学習モデルで両立を実現

[1] 松浪優斗, 西村竜一, 反復した環境音の学習による擬音語認識システムの開発, 日本音響学会学会 2025年春季発表会講演論文集, pp. 989-990, 2025.



チャッガッパッガッガッガッガッガッガッ
パッシャッ

図1. 無作為型 環境音を無作為に10個連結



ガッコンガッコンガッコンガッコンガッコン
チリンカッチリン

図2. 反復型 環境音2個を5回繰り返し（反復）連結



仮説と検証結果

仮説1（条件3と条件4の比較）

あえて種類を減らしたオノマトベをランダムに連結することで反復パターンを表現できる

【仮説1の検証結果】

- 持続性のある環境音の出力性能の向上
反復性のある環境音の出力性能の低下
- 反復性のある環境音へ、出力候補の制限が悪影響





仮説2（条件1と条件3の比較）

作為的に作成した反復パターン（反復型）をモデルの学習に含めないことで不自然な反復の出現を抑制できる

【仮説2の検証結果】

- 瞬発性のある環境音の出力性能の向上
多様性の制限をした無作為型のみでモデルを学習
- 反復性のある環境音の出力性能の向上を示唆



仮説3（条件1と条件2の比較）

無作為型のみで訓練データを作成するとき、作成する訓練データ数を増やすことで反復パターンを表現できる

【仮説3の検証結果】

- 反復性のある環境音の両方で出力性能の低下
- 無作為型の増加は、モデルの学習が複雑化
- 適切な出力を妨げた可能性を示唆





図3. 仮説についての妥当率の比較 [左：仮説1, 中央：仮説2, 右：仮説3] (上：質問1, 下：質問2)

まとめ

- 条件1でモデルを学習することは、反復性のある環境音の出力にたいしても高い妥当率を確認
- 反復型を完全に除くことは、一部の反復性のある環境音に悪影響
- 無作為型の増加は、モデルの学習の複雑化を招き、適切な出力を妨げる
- 質問1と質問2の「○」の回答数は、質問2の方が多い傾向を確認
- 擬音語として許容される範囲は広いことを示唆

今後の課題

- 擬音語（オノマトベ）の言語モデル定義と導入の検討
- 擬音語認識システムのアプリケーション化

【補足1】モデルの学習データ

RWCP-SSD-Onomatopoeia[2][3]

- 環境音サンプルにオノマトベを付与したコーパス
- 1サンプルに複数のオノマトベ（テキスト）が教師ラベルとして定義されている
- 環境音サンプルを時間方向に連結してモデルを学習

表1. モデルごとの訓練データ作成条件

	訓練データ	自信度/許容度	無作為型	反復型
条件1	30,000	4/4.5	100%	-
条件2	120,000	4/4.5	100%	-
条件3	30,000	4/4.5	80%	20%
条件4 先行研究[1]	30,000	4/4	80%	20%

[2] Onomatopoeia, <https://github.com/KeisukeMoto/RWCPSSD-Onomatopoeia/>, (参照 2024-08-08)

[3] Y. Okamoto, K. Imoto, S. Takamichi, R. Yamanishi, T. Fukumori, and Y. Yamashita, "RWCP-SSD-Onomatopoeia: Onomatopoeic Word Dataset for Environmental Sound Synthesis," Proc. Detection and Classification of Acoustic Scenes and Events (DCASE), pp.125-129, 2020.

[4] Karol J. Piczak, ESC: Dataset for Environmental Sound Classification, Proc. ACM Conference on Multimedia, pp. 1015-1018, 2015.

【補足2】評価に使用したデータ

ESC-50[4]のInterior/domestic sounds

（環境音サンプル50個, 10クラス5個）

→ 環境音を3つのカテゴリに分類

- 瞬発性のある環境音（例：缶を開ける音）
- 持続性のある環境音（例：掃除機の音）
- 反復性のある環境音（例：時計の針の音）

【補足3】主観評価の方法

- 実験協力者15名
- ウェブアンケート形式で実施
- 評価用の環境音を聴取, 認識結果を確認
- 設問に二件法（○×）で回答
- 質問1：環境音に対してテキストは音を忠実に書き起こしたものであるとして正しい
- ☆ 質問2：環境音から想像できるテキストとして妥当である

- 本研究における擬音語の定義
物音などを模倣し、その音を表現した言葉