

擬音語認識モデルの学習のための連結環境音の構成法

メディアインテリジェンス研究室

60276266

森山 颯太

概要：本研究では、End-to-End 型擬音語認識モデルの学習データに関する検討を行った。学習には、環境音ペアデータをランダムに 10 個連結した「無作為型」と、2 個を 5 回反復連結した「反復型」の 2 種類の連結信号を利用した。先行研究では、反復型を用いると繰り返し音のリズム感を再現できる一方、非反復音に対して「不自然な繰り返し」が生じる課題が確認された。この誤出力の抑圧に向け、擬音語の多様性の制限、反復型の除外、無作為型の増量という 3 つの仮説に基づき、4 条件の学習データでモデルを構築した。実験の結果、多様性を制限し無作為型のみを用いたモデル（条件 1）は、反復型を混合したモデル（条件 3）よりも、瞬発音や不規則な反復音に対して高い妥当率を示した。具体的には、「缶を開ける音」で 38.7%（条件 3：25.3%）、「ドアのノック音」で 46.7%（同 28.0%）等となり、語彙の制限と反復型の除外が、不自然な繰り返しの抑制や認識性能の維持に有効であることを確認した。一方で、無作為型を増量した条件 2 の平均妥当率は 32.0%に留まり、条件 1 の 36.7%を下回った。

キーワード：擬音語認識システム、環境音、オノマトペ、Hybrid-CTC/Attention

1 はじめに

本研究では、End-to-End(以下、E2E) 型擬音語認識システムの開発を行った。提案した擬音語認識システムでは、環境音の音響信号を入力してオノマトペに近いテキスト（文字列）を出力することができる。

先行研究 [1] では、単独の環境音を時間方向に連結した音響信号をモデルの訓練に用いることを提案した。10 個の音をランダムに繋いだ無作為型と、2 個の音を各 5 回繰り返し反復型の 2 種類のサンプルを用いた。これらを混合してモデルを学習することで、繰り返しパターンを含む環境音の認識結果にリズム感を再現した。しかし、繰り返しパターンを含まない環境音に対しても不自然に繰り返しを出力してしまう課題が残された。

本稿では、繰り返しパターンを含む環境音の認識性能は先行研究 [1] を維持しつつ、繰り返しを含まない環境音の入力に対する認識性能の向上を目指す。

2 擬音語認識システムの実装

本研究での擬音語認識システムの実装には、オープンソースの E2E 音声処理ツールキットである ESPnet2[2] を用いた。深層学習モデルには、Hybrid-CTC/Attention モデル [3] を採用した。このモデルは、12 層 Conformer エンコーダと 6 層 Transformer デコーダで構成されている。損失関数には、CTC、Attention デコーダおよび言語モデルの損失を重み付き和として使用し、それぞれの重みは 0.3、0.7、0.3 とした。

入力信号は 16kHz/16bit のモノラルとし、一般的な STFT（窓長 25ms、シフト幅 10ms）を用いてメルスペクトル特徴に変換した。

モデルの訓練に使用する音響信号には、環境音サンプルに複数の擬音語ラベルが付与された RWCP-SSD-Onomatopoeia [4] を使用した。各ラベルには、付与者

本人の確信度を示す自信度と、第三者による妥当性を示す許容度が付与されている。本研究ではこれらを指標とし、音響特性と適合性の高いサンプルを選択して連結環境音の音響信号を作成した。モデルの訓練に用いる学習データは、この連結環境音信号と、それに対応する擬音語テキストのペアで構成される。

3 比較性能評価

本研究では、3 つの仮説を立て、その仮説に基づいた 4 条件の学習データで訓練したモデルの認識結果を比較した。

仮説 1：あえて種類を減らした擬音語をランダムに連結して繰り返しパターンを表現できる。擬音語の多様性を意図的に制限した上で、モデルによる典型的な繰り返しパターンの学習を促す。具体的には、先行研究 [1] の許容度平均 4.0 以上 (29,349 個) から、4.5 以上 (7,571 個) へと厳格化し、高品質なラベルのみを抽出した。

仮説 2：反復型のモデルの学習に含めないことで不自然な繰り返しの出力を抑制できる。これは、無作為型のみでモデルを訓練することで検証した。

仮説 3：無作為型のみでモデルを学習するとして、使用するデータの量を増やすことで繰り返しパターンを表現できる。無作為型の数を増やすことで、結果として繰り返しパターンも内包するような連結環境音信号が生成されることを期待する。これにより、反復型を含めなくとも、繰り返しパターンを含む信号を受理できるようになると仮定した。

これらの仮説を検証するため、先行研究 [1] と同等の条件（条件 4）を含む 4 つのモデルを構築し、比較した 4 条件の学習データ構成を表 1 に示す。

評価用データには、モデルに対して未知の環境音デー

表 1: 実験で比較したモデルの学習条件 (4 条件)

	学習データ	無作為型 [%]	反復型 [%]
条件 1 (自信度 4, 許容度 4.5)	30,000	100	0
条件 2 (自信度 4, 許容度 4.5)	120,000	100	0
条件 3 (自信度 4, 許容度 4.5)	30,000	80	20
条件 4 (自信度 4, 許容度 4)	30,000	80	20

表 2: クラス別の妥当率 [%] の平均
「○ (妥当)」と回答した数/回答者数)

環境音のクラス	条件 1	条件 2	条件 3	条件 4
缶を開ける音	38.7	28.0	25.3	28.0
ガラスが割れる音	30.7	38.7	22.7	6.7
ドアがさしむ音	14.7	8.0	17.3	13.3
洗濯機の音	28.0	33.3	33.3	16.0
掃除機の音	56.0	61.3	64.0	66.7
時計のアラーム音	57.3	46.7	56.0	72.0
タイピング音	34.7	13.3	44.0	42.7
ドアのノック音	46.7	50.7	28.0	70.7
マウスのクリック音	28.0	17.3	16.0	18.7
時計の針の音	32.0	22.7	38.7	28.0
全体平均	36.7	32.0	34.5	36.3

タセット ESC-50 [5] の Interior/domestic sounds を用いた。同データセットは、擬音語ラベルを含まない環境音の音響信号サンプルが含まれており、10 クラス (各 40 サンプル, 計 400 個) で構成される。

4 つのモデルの出力 50 個 (各クラス 5 サンプル, 10 クラス) に対し、実験協力者 15 名による主観評価を実施した。実験協力者は、入力音を聴取し、出力が「環境音から想像できるテキストとして妥当である」を基準に、二件法 (○×) で評価した。クラス別の「○ (妥当)」の妥当率の平均を表 2 に示す。

条件 3 と条件 4 を比較 (仮説 1: 多様性を制限) すると、妥当率は 36.3% (条件 4) から 34.5% (条件 3) となった。特に、条件 4 のときの「時計のアラーム」や「ドアのノック音」において顕著な劣化を確認した。許容度の基準を厳格化したことで、出力候補となるオノマトペの組み合わせが減っており、一部のクラスにおいては認識性能が低下したことを確認した。

条件 1 と条件 3 の比較 (仮説 2: 無作為型のみで訓練) では、条件 1 (無作為型のみ) で「缶を開ける音」や「ガラスが割れる音」といった瞬発性のある環境音で高い結果を示した。「時計のアラーム音」や「ドアのノック音」といった反復性を含む環境音においても条件 1 (無作為型のみ) の向上を確認した。無作為型のみを用いた場合でも繰り返しパターンを含む環境音の受理は可能であることが示唆された。

条件 1 と条件 2 の比較 (仮説 3: 無作為型のデータ増) では、条件 2 (12 万) の妥当率の全体が 32.0% となり、条件 1 (3 万) の 36.7% から低下している。しかし、クラスごとに確認すると「ガラスが割れる音」や「掃除機の音」の瞬発性のある場合や持続性のある環境音のクラスに対しては向上している。学習データを単純に増やしたことにより、モデルに含まれる不自然なパターンが相対的に増えることになり、ノイズとして機能してしまった恐れがある。

次は、「時計のアラーム音」の出力の例である。

条件 1: チンピッピッピッピッピッピッピッピッピッピッピッピッピッピッピッピッ

条件 2: キンピンピンピンピンピンピン

両条件とも、モデルの訓練に無作為型のみを用いているが、反復を出力に反映できている。しかし、繰り返しパターンで構成される単独のアラーム音は、条件 2 では「キン」「ピン」となり、条件 1 に比べて不適切な結果となった。

4 まとめ・今後の予定

本研究では、End-to-End 型擬音語認識の性能向上を目的に、4 条件の学習データで訓練したモデルを比較した。今回の実験では、無作為型のみで学習したモデルでの認識性能が反復型を混合した場合のモデルを用いたときよりも向上する結果となった。一方で、無作為型の単純の増加は、認識性能の向上に直結しないことが明らかになった。特定のクラスでは依然として反復型を含めた場合 (条件 4) が有利だが、全体的なバランスや不自然な繰り返しの抑制の観点からは、条件 1 でも提案法は機能することが示された。

今後は、環境音に付与に対応するオノマトペの出現頻度や文脈を考慮することができるとする擬音語の言語モデリングを検討の課題とする。

参考文献

- [1] 松浪ら, 音講論 (春), pp. 989–990, 2025.
- [2] S. Watanabe, et al., Proc. Interspeech, pp. 2207–2211, 2018.
- [3] S. Watanabe, et al., IEEE J. Selected Topics in Signal Processing, 11(8), pp. 1240–1253, 2017.
- [4] Y. Okamoto, et al., Proc. DCASE, pp. 125–129, 2020.
- [5] K. J. Piczak, Proc. ACM MM, pp. 1015–1018, 2015.