

無作為連結環境音をモデル学習に用いた E2E 型擬音語認識の性能評価*

☆森山 颯太, 西村 竜一 (和歌山大)

1 はじめに

本研究では、End-to-End(以下、E2E) 型擬音語認識システムの開発を行った。提案した擬音語認識システムでは、環境音の音響信号を入力してオノマトペに近いテキスト（文字列）を出力することができる。

前報 [1] では、単独の環境音を時間方向に連結した音響信号をモデルの訓練に用いることを提案した。10 個の音をランダムに繋いだ無作為型 (Fig. 1) と、2 個の音を各 5 回繰り返した反復型 (Fig. 2) の 2 種類のサンプルを用いた。これらを混合してモデルを学習することで、繰り返しパターンを含む環境音の認識結果にリズム感を再現した。しかし、繰り返しパターンを含まない環境音に対しても不自然に繰り返しを出力してしまうという過適合が課題として残された。

本稿では、繰り返しパターンを含む環境音の出力精度は先行研究 [1] を維持しつつ、繰り返しを含まない環境音の入力に対する出力精度の向上を目指す。

2 擬音語認識システムの実装

本研究での擬音語認識システムの実装には、オープンソースの E2E 音声処理ツールキットである ESPnet2[2] を用いた。深層学習モデルには、Hybrid-CTC/Attention モデル [3] を採用した。このモデルは、12 層 Conformer エンコーダと 6 層 Transformer デコーダで構成されている。損失関数には、CTC、Attention デコーダおよび言語モデルの損失を重み付き和として使用し、それぞれの重みは 0.3, 0.7, 0.3 とした。

入力音響信号は、サンプリング周波数 16 kHz、量子化ビット数 16 bit のモノラル音声である。音響信号の分析条件として、短時間フーリエ変換 (STFT) の窓長を 400 サンプル (25 ms)、シフト幅を 160 サンプル (10 ms)、FFT サイズを 512 サンプルとした。メルフィルタバンクを適用し、入力信号をメルスペクトル特徴に変換し、モデルへの入力とする。

モデルの訓練に使用する音響信号には、環境音サンプルに複数の擬音語ラベルが付与された RWCP-SSD-Onomatopoeia [4] を使用した。各ラベルには、付与者本人の確信度を示す自信度と、第三者による妥当性を示す許容度が付与されている。本研究ではこれらを指標とし、音響特性と適合性の高いサンプルを選択して連結環境音の音響信号を作成した。モデルの




Fig. 1: 環境音サンプルの連結（無作為型）




Fig. 2: 環境音サンプルの連結（反復型）

訓練に用いる学習データは、この連結環境音信号と、それに対応する擬音語テキストのペアで構成される。

3 比較性能評価

本研究では、3つの仮説を立て、その仮説に基づいた 4 条件の学習データで訓練したモデルの認識結果を比較した。

仮説 1: あえて種類を減らした擬音語をランダムに連結して繰り返しパターンを表現できる。擬音語の多様性を意図的に制限した上で、モデルによる典型的な繰り返しパターンの学習を促す。具体的には、先行研究の許容度平均 4.0 以上 (29,349 個) から、4.5 以上 (7,571 個) へと厳格化し、高品質なラベルのみを抽出した。

仮説 2: 反復型の学習データをモデルの学習に含めないことで不自然な繰り返しの出力を抑制できる。これは、無作為型のみで連結環境音信号でモデルを訓練することで検証した。

仮説 3: 無作為型のみで学習データを作成することで、使用するデータの量を増やすことで反復パターンを表現できる。無作為型の数を増やすことで、結果として繰り返しパターンも内包するような連結環境音信号が生成されることを期待する。これにより、反復型のサンプルを含めなくとも、反復パターンを含む信号を受理できるようになると仮定した。

これらの仮説を検証するため、先行研究と同等の

*Evaluation of E2E Onomatopoeia Recognition using Randomly Concatenated Environmental Sounds for Model Training. by MORIYAMA, Sota, NISIMURA, Ryuichi (Wakayama University)

